

Rostand Surel

À la recherche d'un CDI — Data Scientist / ML Engineer — 5 ans d'expérience

☎ 075-335-6106 — ✉ rostandsurel@yahoo.com — in linkedin.com/in/rostand-surel — 🐙 github.com/Manda404 — 📁 Portfolio — 📍 Paris, France

Compétences

- **Machine Learning** : XGBoost, LightGBM, CatBoost, Scikit-Learn, Feature Engineering, SHAP, LIME, Évaluation modèle
- **IA Générative & NLP** : LLM, LangChain, LangGraph, RAG, Embeddings, Pinecone, Databricks Vector Search, agents IA
- **MLOps** : MLflow, DVC, FastAPI, CI/CD, Docker, Grafana, Prometheus, Data/Model Drift
- **Big Data & Cloud** : PySpark, Databricks, Kafka, Airflow, NiFi
- **Programmation** : Python, Pandas, NumPy, Streamlit, SQL, Conception d'API, Git
- **Langues** : Français (C2), Italien (B2), Anglais (B2)

Certifications

- Databricks Certified Data Engineer Associate 
- Databricks Certified Generative AI Engineer Associate 
- Databricks Certified Machine Learning Associate 
- Databricks Certified Machine Learning Professional 

Expériences Professionnelles

Bulls

Fév. 2026 – Présent

Consultant AI Engineer, Bezons, France

- Objectif** : Développer un agent RAG intégré à une plateforme Agentic AI pour interroger les connaissances d'entreprise.
- Automatiser l'ingestion de contenus **SharePoint** et **GitHub** avec **Auto Loader** pour alimenter la Knowledge Base.
 - Développer un agent **RAG** pour interroger la Knowledge Base et générer des réponses contextualisées.
 - Intégrer les connaissances stockées dans **Unity Catalog** à une plateforme **Agentic AI** via des services **FastAPI**.

Résultat : Prototype Agentic AI opérationnel intégrant ingestion, structuration et exploitation de connaissances d'entreprise.

Assurances AXA

Janv. 2025 – Janv. 2026

Consultant Data Scientist, Préfecture de Nanterre, France

- Objectif** : Prédire la résiliation client à grande échelle et industrialiser les modèles pour améliorer l'efficacité marketing.
- Explorer et transformer des datasets massifs (~5M) sur **Databricks** avec **PySpark**, pour créer des variables pertinentes.
 - Entraîner des modèles marketing avec **XGBoost** et **CatBoost**, pour prédire le churn via une *cross-validation robuste*.
 - Structurer des packages **Python** testés unitairement et automatiser les déploiements via **Azure Pipelines**.
 - Déployer des modèles ML avec **Databricks Model Serving** afin d'intégrer les prédictions aux applications CRM.

Résultat : +18 % de précision sur les clients à risque et amélioration des performances des campagnes de rétention.

Safran Seats

Avr. 2024 – Déc. 2024

Data Scientist, Issoudun, France

- Objectif** : Optimiser le processus de conception des sièges en simulant le confort à partir des données expérimentales.
- Concevoir une architecture de données pour structurer efficacement les données de tests de confort des sièges d'avion.
 - Implémenter des pipelines d'ingestion et de transformation pour alimenter les tables analytiques et fiabiliser les données.
 - Développer des dashboards interactifs pour analyser les tests de confort et identifier des insights utiles aux équipes R&D.

Résultat : +65 % de gain de temps dans l'analyse des données de tests de confort grâce à l'automatisation et à l'interface.

ICTeam S.p.A

Sept. 2020 – Nov. 2023

Consultant Data Engineer / Data Scientist, Milan, Italie

Consultant – Sky TV

Objectif : Développer une segmentation prédictive pour améliorer le ciblage CRM et l'engagement des abonnés Sky TV.

- Développer des **pipelines Spark/SQL** pour consolider les données clients et préparer les jeux d'entraînement ML.
- Entraîner des modèles **XGBoost** pour segmenter les clients et optimiser les performances via **validation croisée**.
- Suivre les expérimentations **MLflow** pour comparer les modèles et versionner les artefacts avant mise en production.
- Analyser les résultats d'**A/B tests** pour comparer les campagnes et mesurer l'impact des stratégies de ciblage.

Résultat : +24 % d'efficacité des campagnes ciblées, avec une meilleure activation des segments à haut potentiel.

Consultant – Kuwait Petroleum S.p.A

Objectif : Moderniser l'architecture data pour fiabiliser et automatiser la gestion des données de distribution de carburants.

- Automatiser l'ingestion des données avec **Apache NiFi** et fiabiliser les flux de collecte métiers multi-sources.
- Concevoir des **tables Hive** pour structurer les données et faciliter les analyses opérationnelles de distribution.
- Développer des traitements **PySpark** pour transformer les données et améliorer leur qualité avant exploitation.
- Orchestrer les **workflows Airflow** pour automatiser les traitements et sécuriser les exécutions quotidiennes.

Résultat : Réduction des traitements manuels et fiabilisation des flux data grâce à l'automatisation des pipelines d'ingestion.

Education

Master en Science des données et Intelligence Artificielle — ECE, Lyon, France, 2023 – 2024

Licence en Ingénierie Informatique — École Polytechnique de Turin, Turin, Italie, 2017 – 2020