

Rostand Surel

À la recherche d'un CDI — Data Scientist / ML Engineer — 4 ans d'expérience

☎ 075-335-6106 — ✉ rostandsurel@yahoo.com — in linkedin.com/in/rostand-surel — 🌐 github.com/Manda404 — 📍 Versailles, France

Compétences

- **Machine Learning** : XGBoost, LightGBM, CatBoost, Scikit-Learn, Feature Engineering, SHAP, LIME, Évaluation modèle
- **IA Générative & NLP** : GPT, BERT, LangChain, RAG, Prompt Engineering, Hugging Face, Embeddings, Pinecone, FAISS
- **MLOps** : MLflow, DVC, FastAPI, CI/CD, Docker, Grafana, Prometheus, Azure DevOps, Data/Model Drift
- **Big Data & Cloud** : PySpark, Databricks, Kafka, Airflow, NiFi, AWS, Azure, Feature Store
- **Programmation** : Python (Pandas, NumPy, Seaborn), SQL, Conception d'API, Git
- **Langues** : Français (C2), Italien (B2), Anglais (B2)

Certifications

- Databricks Certified Machine Learning Associate 
- Databricks Certified Generative AI Engineer Associate 

Expériences Professionnelles

Assurances AXA

Janv. 2025 → Présent

Consultant Data Scientist, Préfecture de Nanterre, France

Objectif : Prédire la résiliation client à grande échelle et industrialiser les modèles pour améliorer l'efficacité marketing.

- **Exploré** et transformé des datasets massifs (~5M) sur **Databricks** avec **PySpark**, pour créer des variables pertinentes.
- **Entraîné** des modèles marketing avec **XGBoost** et **CatBoost**, pour prédire le churn via une *cross-validation robuste*.
- **Structuré** des pipelines de données dans des **packages Python** testés unitairement et déployés via **Azure Pipelines CI/CD**.
- **Déployé** des modèles ML avec **Databricks Model Serving** afin d'intégrer les prédictions aux applications CRM.

Résultat : +18 % de précision sur les clients à risque et amélioration des performances des campagnes de rétention.

Safran Seats

Avr. 2024 → Nov. 2024

Data Scientist, Issoudun, France

Objectif : Optimiser le processus de conception des sièges en simulant le confort à partir des données expérimentales.

- **Nettoyé, structuré et enrichi** les données de test de **confort** des sièges d'avion pour garantir leur **qualité** et **pertinence**.
- **Optimisé** la gestion des tests de confort des sièges d'avion grâce à un modèle de données évolutif sous **PostgreSQL**.
- **Développé** un dashboard analytique interactif pour visualiser les données de tests et extraire des insights métier.
- **Créé** une **assistante IA SQL** basée sur **Large Language Model (SQLCoder)**, pour simplifier l'accès aux requêtes **SQL**.

Résultat : +65 % de gain de temps dans l'analyse des données de tests de confort grâce à l'automatisation et à l'interface.

Sky TV

Oct. 2022 → Nov. 2023

Consultant Data Scientist, Milan, Italie

Objectif : Construire un moteur de segmentation prédictive pour cibler les clients à fort potentiel en CRM personnalisé.

- **Effectué** une analyse exploratoire des données avec **Spark** afin de détecter les anomalies, corriger les incohérences.
- **Développé des requêtes SQL** pour extraire les données et **réalisé une analyse exploratoire de données** avec **Python**.
- Conçu de modèles de **recommandation** basés sur l'**apprentissage profond** afin de proposer des offres personnalisées.
- **Entraîné et optimisé** le modèle de **XGBoost**, avec un suivi structuré des performances et des versions via **MLflow**.

Résultat : +24% d'efficacité des campagnes ciblées, avec une meilleure activation des segments à haut potentiel.

Kuwait Petroleum S.p.A

Sept. 2020 → Oct. 2022

Consultant Data Engineer, Milan, Italie

Objectif : Moderniser l'architecture data pour fiabiliser et automatiser la gestion des données de distribution de carburants.

- Automatisé la collecte et l'ingestion des données avec **Apache NiFi**, stockées dans **HDFS** pour un traitement distribué.
- **Conçu** et maintenu des tables **Hive (HiveQL)** pour structurer et interroger les données de production de carburants.
- **Développé** des jobs de traitement distribué des données avec **PySpark**, optimisant ainsi l'efficacité des analyses.
- **Orchestré** les workflows avec **Airflow**, augmentant la fiabilité des processus de collecte, transformation et stockage.

Résultat : Pipeline de données robuste et scalable, réduisant les erreurs de collecte de **40%** sur des sources multiples.

Applications Avancées en Data Science & GenIA

- **BrevetAnalyzer IA** : Développement d'un **outil intelligent d'analyse brevets** basé sur une architecture **RAG (moteur de recherche sémantique, IA générative, innovation, productivité)** avec interface **Streamlit** et déploiement sur **AWS**.
Impact : Recherche brevets accélérée de **65 %**, détection proactive des innovations concurrentes, adoption par R&D.

Education

Master en Science des données et Intelligence Artificielle — ECE, Lyon (France), 2023 – 2024

Licence en Ingénierie Informatique — École polytechnique de Turin, Turin (Italie), 2017 – 2020